

Evaluación de Arquitecturas Transformer para la Predicción del Precio de Cierre en Mercados Bursátiles: Un Estudio Comparativo en JPMorgan y Alicorp con Validación Estadística Rigurosa

Mirian Lucero Ancco Ancalla

Universidad Nacional de San Antonio Abad del Cusco (UNSAAC)
mirianancco7@gmail.com

Resumen—Este trabajo presenta una evaluación comparativa de arquitecturas Transformer aplicadas a la predicción del precio de cierre a corto plazo (1 y 5 días) de dos activos bursátiles: JPMorgan Chase (NYSE:JPM) y Alicorp (BVL:ALICORC1). Se desarrollaron tres niveles de madurez del modelo: una réplica base (*General*), una variante metodológicamente reforzada (*Mejorado*) con regresión cuantílica, ensemble profundo, baselines lineales obligatorios y validación estadística extendida, y una extensión de fusión de sentimiento basada en FinBERT. Siguiendo la observación de que la mayoría de los estudios de deep learning aplicado a mercados financieros omiten un backtesting riguroso, se evaluaron todas las variantes mediante un backtest walk-forward de 500 días bursátiles (reentrenamiento cada 20 días) frente a un baseline naive de persistencia y frente a baselines lineales (NLinear/DLinear), utilizando las pruebas de Wilcoxon, Diebold-Mariano (con corrección de muestra pequeña de Harvey-Leybourne-Newbold) y bootstrap por bloques circular. Los resultados no muestran una ventaja predictiva estadísticamente robusta para la réplica base en ninguno de los dos activos (JPM: 54.2% de precisión direccional, $p=0.835$; Alicorp: 48.6%, no significativo), mientras que la variante reforzada alcanza 61.8% de precisión direccional en JPM con una significancia parcial, confirmada solo por una de las tres pruebas frente al baseline naive, aunque robusta frente a ambos baselines lineales en las tres pruebas. El seguimiento en vivo fuera de muestra, durante 12 jornadas bursátiles reales, corrobora el mismo ordenamiento (83.3% frente a 41.7% de precisión direccional). Se discuten estos resultados en el contexto de la literatura que cuestiona la superioridad de los Transformers sobre baselines más simples, y se argumenta que el aporte principal de este trabajo no es una señal de trading rentable, sino una medición metodológicamente transparente de la ventaja — pequeña y parcial — que la validación rigurosa permite, y no permite, sostener.

Palabras clave—Transformer, auto-atención, predicción de series temporales, precio de acciones, backtesting walk-forward, regresión cuantílica, análisis de sentimiento, FinBERT.

I. INTRODUCCIÓN

La predicción del precio de cierre de instrumentos bursátiles mediante aprendizaje profundo ha recibido una atención creciente desde la introducción de la arquitectura Transformer [1], cuyo mecanismo de auto-atención elimina el cuello de botella secuencial de las redes recurrentes. Sin embargo, dos limitaciones recurrentes debilitan buena parte de esta literatura aplicada a finanzas: por un lado, trabajos como [4] y [7] muestran que modelos lineales de una sola capa igualan o superan a Transformers sofisticados en benchmarks de forecasting de series temporales; por otro, [9] encuentra, en una revisión sistemática, que apenas el 0.35% de los estudios de deep learning en mercados bursátiles aplica un protocolo de backtesting suficientemente riguroso como para sostener sus conclusiones.

Este trabajo responde a ambas limitaciones dentro de un mismo estudio de caso. Se comparan tres niveles progresivos de madurez metodológica de un mismo modelo Transformer-encoder aplicado a dos activos — JPMorgan Chase y Alicorp — y se somete la variante más avanzada a un protocolo de validación de dos años (500 días bursátiles), con reentrenamiento periódico, comparación contra

baselines naive y lineales, y tres pruebas estadísticas de significancia complementarias. Se añade, además, una validación fuera de muestra mediante seguimiento diario en vivo y operaciones reales de bajo capital, y una extensión exploratoria que incorpora análisis de sentimiento de noticias mediante FinBERT.

Las contribuciones de este trabajo son: (i) un backtest walk-forward de 500 días sobre dos activos y tres variantes de arquitectura; (ii) la comparación sistemática contra baselines naive y lineales bajo tres pruebas estadísticas de distinta exigencia; (iii) una validación fuera de muestra con datos de mercado genuinamente no vistos; y (iv) una extensión de fusión de sentimiento como primer paso hacia un modelo multimodal.

II. TRABAJOS RELACIONADOS

La arquitectura Transformer [1] constituye la base de este trabajo mediante su mecanismo de auto-atención multi-cabeza y codificación posicional. Extensiones posteriores abordan las series de tiempo específicamente: Informer [2] introduce atención dispersa (ProbSparse) para secuencias largas y predicción directa

multi-horizonte, mientras que el Temporal Fusion Transformer (TFT) [3] combina variables estáticas y covariables dinámicas con regresión cuantílica interpretable. Revisiones recientes [5], [6] documentan la taxonomía de arquitecturas Transformer para forecasting y sus retos de reproducibilidad.

Un segundo grupo de trabajos cuestiona esta premisa: [4] muestra que modelos lineales (NLinear, DLinear) igualan o superan a Transformers en la mayoría de los benchmarks de largo plazo, y [7] extiende este análisis a la estabilidad de entrenamiento y la significancia estadística de las comparaciones. Este trabajo incorpora directamente ambos baselines lineales como control metodológico.

En el dominio bursátil específico, [8] aplica Transformers a la predicción de cierre en un mercado emergente (Bolsa de Arabia Saudita), un precedente cercano al caso de Alicorp. [11] extiende TFT con múltiples fuentes de datos (precio, volumen, sentimiento) optimizando directamente por Sharpe ratio. [9] aporta el marco de referencia para el protocolo de backtesting adoptado aquí, y [10] motiva el modelado probabilístico de la dirección y magnitud del movimiento de precio, así como el bootstrap por bloques utilizado en la validación estadística. La cuantificación de incertidumbre combina MC Dropout [12] y deep ensembles [13]; la comparación de pronósticos utiliza el test de Diebold-Mariano [14] con la corrección de muestra pequeña de Harvey, Leybourne y Newbold [15].

III. METODOLOGÍA

A. Datos

Se utilizaron series históricas diarias (OHLC) de JPMorgan Chase (NYSE:JPM) y Alicorp (BVL:ALICORC1). Las variables de entrada (*features*) son el precio de cierre y una media móvil simple de 5 días (SMA_5) en ambas variantes; la variante Mejorado añade el logaritmo del volumen negociado (Volume_log), siguiendo [11].

B. Arquitectura

El modelo es un Transformer de tipo encoder-only. Una ventana de *lookback* de 10 días se trata como una secuencia de tokens, proyectada a una dimensión oculta $d_{\text{modelo}}=64$ mediante una capa lineal, sumada a codificación posicional sinusoidal [1]. El encoder

consta de 2 capas de auto-atención con 4 cabezas y una red feed-forward de dimensión 256 (dropout=0.1). El vector correspondiente al token más reciente se envía a la cabeza de salida, que predice el cambio (delta) de precio, no su nivel absoluto. En la variante Mejorado, la salida se bifurca en una cabeza de cuantiles (q10/q50/q90, entrenada con pinball loss, siguiendo [3]) y una cabeza auxiliar de volatilidad (activación softplus), combinadas en una función de pérdida compuesta.

C. Cuantificación de incertidumbre

La variante General estima incertidumbre mediante MC Dropout (50 pasadas) [12]; la variante Mejorado combina MC Dropout con un ensemble de 5 semillas aleatorias [13], agregando la varianza total según la ley de varianza total.

D. Baselines

Ambas variantes se comparan contra un baseline naive de persistencia (el precio de mañana es igual al de hoy). La variante Mejorado añade además NLinear y DLinear [4] como baselines lineales obligatorios.

E. Protocolo de validación

Siguiendo [9], se adoptó un backtest walk-forward de 500 días bursátiles (~2 años) con reentrenamiento cada 20 días, sobre una ventana expandible, segmentado por tercil de régimen de volatilidad. La significancia de la diferencia de error frente a cada baseline se evaluó con tres pruebas de exigencia creciente: el test de rangos con signo de Wilcoxon, el test de Diebold-Mariano [14] con la corrección de Harvey-Leybourne-Newbold para muestra pequeña [15], y un bootstrap por bloques circular [10], que modela la autocorrelación del error de pronóstico de forma más realista que un test no paramétrico simple.

F. Extensión: fusión de sentimiento

Como extensión exploratoria, se construyó un componente que obtiene titulares de noticias de JPM mediante la API de Finnhub, los clasifica con FinBERT (ProsusAI/finbert, modelo preentrenado, sin ajuste adicional) en positivo/negativo/neutral ponderado por confianza, y combina el promedio diario resultante con la señal normalizada (z-score) de la variante Mejorado mediante una regla de fusión explícita y reproducible: $\text{score}_{\text{final}} = 0.5 \times \text{código}(z_{\text{modelo}}) + 0.5 \times \text{sentimiento}_{\text{FinBERT}}$.

TABLA I
Resultados del backtest walk-forward (500 días bursátiles, ~2 años; 150 días para Alicorp)

Modelo	Direccional	MAE (modelo / naive)	Significancia vs. naive	Significancia vs. lineales
Alicorp — General	45.3–48.6%	0.105 / 0.104	No (p=0.390)	—
JPMorgan — General	54.2%	6.9887 / 6.9923	No (p=0.835)	—
JPMorgan — Mejorado	61.8%	6.8478 / 7.0733	Parcial (1/3 pruebas, p=0.014)	Sí (3/3 pruebas)




Fig. 1. Precisión direccional a 5 días por modelo y activo sobre el backtest completo (Tabla I), con la línea de referencia de acierto por azar (50%). Solo la variante Mejorada supera claramente ese umbral.

IV. RESULTADOS

La Tabla I y la Fig. 1 resumen el resultado del backtest de 500 días para los tres pares modelo-activo evaluados. La réplica base (General) no muestra ventaja estadísticamente significativa frente al baseline naive en ninguno de los dos activos. La variante Mejorada alcanza la mayor precisión direccional (61.8%) y el menor error absoluto medio del conjunto, con significancia confirmada por el test de Wilcoxon ($p=0.014$) pero no por Diebold-Mariano ($p=0.685$) ni por el bootstrap por bloques ($p=0.111$, IC 95% $[-0.05, 0.49]$) — los dos tests que modelan de forma más

realista la autocorrelación del error. Frente a los baselines lineales NLinear y DLinear, en cambio, la ventaja de Mejorada es robusta y se confirma en las tres pruebas.

El seguimiento fuera de muestra durante 12 jornadas bursátiles reales posteriores al backtest (28/07–12/08/2026, datos nunca vistos por ningún modelo) corrobora el mismo ordenamiento (Fig. 2): la variante Mejorada acertó la dirección en 10 de 12 días (83.3%, error medio 0.83%), frente a 5 de 12 (41.7%, error medio 0.94%) de la variante General — utilizando exactamente las mismas 12 jornadas para ambos modelos.




Fig. 2. Cierre real de JPM y predicciones de las variantes General y Mejorada durante las 12 jornadas de seguimiento en vivo fuera de muestra (28/07–12/08/2026). Eje vertical en USD por acción.

La validación cualitativa en condiciones de mercado real (una cuenta de *paper trading* y una cuenta con capital real de bajo monto) reproduce la misma tendencia: la variante Mejorada registró 4 operaciones ganadoras de 4 en *paper trading* (+59.61 USD) y una posición sostenida con capital real; la variante General aplicada a Alicorp registró 0 operaciones ganadoras de 2 (−194.39

USD), motivando la discontinuación de ese activo tras la convergencia de tres señales independientes: ausencia de ventaja en el backtest, resultado negativo en mercado real, y costo de oportunidad frente a JPMorgan.

El componente de fusión de sentimiento se evaluó en su primera jornada de producción (13/08/2026): sobre 22 titulares procesados,

el sentimiento promedio (+0.059) y la señal del modelo ($z=0.246$) resultaron ambos débiles, produciendo un score final de fusión de 0.030 y una recomendación de no operar — un único día de historial no permite, por sí solo, ninguna conclusión estadística sobre el aporte del componente de sentimiento.

V. DISCUSIÓN

Los resultados son consistentes con la literatura que cuestiona la superioridad general de los Transformers en forecasting de series de tiempo [4], [7]: la variante base no logra superar de forma robusta ni siquiera al baseline naive más simple. Sin embargo, el hallazgo no es homogéneo: cuando se incorporan las mejoras metodológicas de la variante Mejorado — cuantiles, ensemble, backtest extendido, baselines lineales explícitos —, emerge una ventaja pequeña pero consistente frente al baseline naive (confirmada por una de tres pruebas y por el seguimiento en vivo posterior) y una ventaja robusta frente a los propios baselines lineales que la literatura señala como difíciles de superar. Esto sugiere que la arquitectura Transformer sí puede aportar

valor incremental sobre alternativas lineales, condicionado a un protocolo de entrenamiento y validación considerablemente más exigente que el habitual en la literatura revisada por [9].

Una observación metodológica relevante es la discrepancia entre pruebas estadísticas: el test de Wilcoxon, al ser el más simple y no modelar autocorrelación temporal del error, resultó el único en marcar significancia frente al naive. Esta discrepancia respalda la recomendación de [9] y [10] de reportar múltiples pruebas de distinta exigencia en lugar de una sola, dado que un test aislado (Wilcoxon) habría producido una conclusión optimista no sostenida por pruebas más apropiadas para datos con dependencia temporal.

VI. LIMITACIONES

- El tamaño de muestra del backtest de Alicorp (150 días) es menor al de JPMorgan (500 días), lo que limita la comparabilidad directa entre activos, aunque no afecta las conclusiones intra-activo.
- El capital empleado en la validación con dinero real

es deliberadamente pequeño (unos pocos dólares), por lo que constituye una prueba de proceso y no una validación financiera.

- El componente de fusión de sentimiento cuenta, al momento de escribir este trabajo, con un solo día de historial, insuficiente para cualquier inferencia estadística sobre su aporte predictivo.
- Los hiperparámetros (incluyendo el *lookback* de 10 días) se fijaron una única vez sobre un activo distinto (IFS) y se reutilizaron sin reajuste por activo, para evitar sobreajuste a una serie particular, a costa de no explorar configuraciones potencialmente mejores por activo.

VII. CONCLUSIÓN

Este trabajo evaluó tres niveles de madurez de un modelo Transformer-encoder para la predicción del precio de cierre en dos activos bursátiles, bajo un protocolo de validación estadística explícitamente más riguroso que el habitual en la literatura del área [9]. La variante base no mostró ventaja robusta sobre un baseline naive en ningún activo; la variante

metodológicamente reforzada mostró una ventaja pequeña, parcial y dependiente de la prueba estadística aplicada frente al naive, pero robusta frente a baselines lineales — resultado corroborado por 12 jornadas de seguimiento en vivo fuera de muestra. Se argumenta que esta medición honesta, con sus matices y limitaciones explícitas, constituye en sí misma la contribución principal del trabajo, dado que [9] encuentra que menos del 1% de los estudios comparables aplica un nivel de rigor equivalente.

VIII. TRABAJO FUTURO

Las líneas de trabajo futuro incluyen: extender el seguimiento en vivo del componente de sentimiento hasta acumular potencia estadística suficiente; incorporar el sentimiento como variable de entrada directa del Transformer en lugar de una fusión posterior; y, si emergiera una señal predictiva inicial en un nuevo activo, replicar sobre él el protocolo completo de la variante Mejorado, siguiendo el mismo criterio de asignación de esfuerzo aplicado en este trabajo entre JPMorgan y Alicorp.

REFERENCIAS

- [1] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, Ł. Kaiser, and I. Polosukhin, "Attention is all you need," *arXiv:1706.03762*, 2017.
- [2] H. Zhou, S. Zhang, J. Peng, S. Zhang, J. Li, H. Xiong, and W. Zhang, "Informer: Beyond efficient transformer for long sequence time-series forecasting," in *Proc. AAAI Conf. Artif. Intell.*, 2021.
- [3] B. Lim, S. Ö. Arik, N. Loeff, and T. Pfister, "Temporal fusion transformers for interpretable multi-horizon time series forecasting," *arXiv:1912.09363*, 2020.
- [4] A. Zeng, M. Chen, L. Zhang, and Q. Xu, "Are transformers effective for time series forecasting?," *arXiv:2205.13504*, 2022.
- [5] J. Zhao, F. Chu, L. Xie, Y. Che, Y. Wu, and A. F. Burke, "A survey of transformer networks for time series forecasting," *Comput. Sci. Rev.*, vol. 60, p. 100883, 2026.
- [6] R. P. dos Santos, J. P. Matos-Carvalho, and V. R. Q. Leithardt, "Deep learning in time series forecasting with transformer models and RNNs," *PeerJ Comput. Sci.*, vol. 11, p. e3001, 2025.
- [7] A. Miño Calero, A. Rasheed, and A. M. Lekkas, "Unveiling the limitations of transformer models in time series forecasting," *Prog. Artif. Intell.*, 2026, doi: 10.1007/s13748-026-00450-y.
- [8] N. Malibari, I. Katib, and R. Mehmood, "Predicting stock closing prices in emerging markets with transformer neural networks: The Saudi stock exchange case," *Int. J. Adv. Comput. Sci. Appl.*, vol. 12, no. 12, p. 876, 2021.

- [9] K. Olorunnimbe and H. Viktor, "Deep learning in the stock market—a systematic survey of practice, backtesting, and applications," *Artif. Intell. Rev.*, vol. 56, pp. 2057–2109, 2022.
- [10] Y.-S. Lim and D. Gorse, "Deep probabilistic modelling of price movements for high-frequency trading," *arXiv:2004.01498*, 2020.
- [11] J. Yang, P. Li, Y. Cui, X. Han, and M. Zhou, "Multi-sensor temporal fusion transformer for stock performance prediction: An adaptive Sharpe ratio approach," *Sensors*, vol. 25, p. 976, 2025.
- [12] Y. Gal and Z. Ghahramani, "Dropout as a Bayesian approximation: Representing model uncertainty in deep learning," in *Proc. Int. Conf. Mach. Learn.*, 2016, pp. 1050–1059.
- [13] B. Lakshminarayanan, A. Pritzel, and C. Blundell, "Simple and scalable predictive uncertainty estimation using deep ensembles," in *Proc. Adv. Neural Inf. Process. Syst.*, 2017.
- [14] F. X. Diebold and R. S. Mariano, "Comparing predictive accuracy," *J. Bus. Econ. Stat.*, vol. 13, no. 3, pp. 253–263, 1995.
- [15] D. Harvey, S. Leybourne, and P. Newbold, "Testing the equality of prediction mean squared errors," *Int. J. Forecast.*, vol. 13, no. 2, pp. 281–291, 1997.